



ВСЕРОССИЙСКАЯ ОЛИМПИАДА ПО ИСКУССТВЕННОМУ ИНТЕЛЛЕКТУ- 2024

Сборник методических материалов

Москва

2024


Авторы заданий:

КАНТОНИСТОВА Елена Олеговна	Доцент Департамента больших данных и информационного поиска, кандидат физико-математических наук, ФГАОУ ВО «Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ)
ЗАБАШТА Алексей Сергеевич	Доцент факультета информационных технологий и программирования, кандидат технических наук, Университет ИТМО
ПАТОЧЕНКО Евгений Анатольевич	Старший преподаватель Департамента больших данных и информационного поиска, ФГАОУ ВО «Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ)
ПУСЕВ Руслан Сергеевич	Преподаватель факультета физико-математических и компьютерных наук, кандидат физико-математических наук, ФГАОУ ВО «Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ)
РОГАЧЕВ Александр Игоревич	Аспирант Департамента больших данных и информационного поиска, НИУ ВШЭ; старший программист-исследователь; команда компьютерного зрения, VK
МАЛЕЕВ Алексей Викторович	Директор центра развития ИТ-образования ФГАОУ ВО «Московский физико-технический институт (национальный исследовательский университет)» (МФТИ), директор Высшей школы программной инженерии МФТИ

Содержание:

- 1. Задания Всероссийской олимпиады по искусственному интеллекту – 2024**
- 2. Требования к необходимым знаниям и умениям участников**
- 3. Требования к оборудованию рабочих мест**
- 4. Ресурсы для подготовки**

Отборочный этап



Завершить тест



Вопрос 1

Ровно в полночь лиса Алиса и кот Базилио выкопали на Поле чудес золотые биткойны, посаженные Буратино. Для надежности, лиса Алиса оставила их у себя. Окрыленные своим успехом, ровно в полночь они отправились в харчевню «Три пескаря». Двигаясь с постоянной скоростью V , через некоторое время кот Базилио был уже там. Однако, заподозрив неладное, он решил вернуться и побежал из таверны в обратном направлении и выбежал из таверны со скоростью kV . Они встретились у Большого Дуба, что вызвало подозрение подозрения у Базилио. Тогда, под предлогом забытых на Поле Чудес своих очков, он отправился туда с той же скоростью kV .

Оказавшись на Поле Чудес, забрав пропажу и не потратив ни секунды, кот Базилио поспешил обратно с изначальной скоростью V . Пройдя мимо дуба без остановки и убедившись, что подозрения беспочвенны, он отправился в харчевню и оказался там с лисой Алисой в одно и то же время — через T часов после полуночи. Считайте, что беглого осмотра дерева было достаточно и этим временем можно пренебречь, а лиса действительно вне подозрений.

В какое время кот Базилио оказался у Большого Дуба, когда возвращался с Поля Чудес во второй раз?

$k = 2$
 $V = 2$
 $T = 9$


Ваш ответ:

Ответом на данный вопрос является целое число или десятичная дробь. Разделителем может служить как точка, так и запятая.

Ответить



1



Завершить тест

Вопрос 1

Чтобы спасти вымирающий вид сумчатых куниц, на остров Тасмания была отправлена экспедиция из X участников.

Куницам свойственно бесцельно бродить по острову в одиночестве. Вероятность поймать самку-куницу изначально равна Y . Для того, чтобы получить пару (самец и самка), пришлось поймать Z куниц.

Вычислите вероятность того, что последняя куница оказалась самкой, при условии, что всего пришлось поймать Z куниц.

$X = 15$
 $Y = 0.45$
 $Z = 6$

Ваш ответ:

Ответом на данный вопрос является целое число или десятичная дробь. Разделителем может служить как точка, так и запятая.

Ответить

[F] Предпринимательский инстинкт: выявляем будущих владельцев бизнеса

К решению задач

Тренажер

Для реализации собственного бизнеса его необходимо официально зарегистрировать. Банки заинтересованы в том, чтобы люди обращались к ним за этой услугой. Информация о том, кто из клиентов готов начать свое дело, помогает банкам оптимизировать маркетинговые кампании, улучшить персонализированные предложения и экономить ресурсы. Ваша задача — найти людей, наиболее похожих на тех, кто уже открыл бизнес после коммуникации с банком.

Данные:

В этой задаче вам предстоит разработать модель, которая будет определять вероятность регистрации клиентами ИП или ООО в ближайшие дни после персональной коммуникации с банком.

- train.csv** csv включает как данные о клиентах, зарегистрировавших бизнес в период с мая по август 2023 года в течение 14 дней после коммуникации, так и данные о клиентах, которые не зарегистрировали бизнес в этот промежуток времени.
- test.csv** содержит информацию о клиентах, для которых необходимо предоставить предсказание вашей модели.

В вашем распоряжении будут разнообразные признаки клиентов, такие как:

- mb** — информация о различных сессиях в мобильном приложении,
- application** — заявки на продукты банка,
- bki** — характеристики обращения в бюро кредитных историй,
- partner** — информация о подписках на партнерские сервисы,
- graph** — данные о контактных книжках клиентов,
- feature** — другие анонимизированные признаки,
- target** — значение целевой переменной, указывающей наличие (1) или отсутствие (0) регистрации ИП или ООО.

В качестве решения загрузите csv-файл, содержащий индексы объектов из тестовой выборки и предсказания вероятностей регистрации, полученные с помощью вашего решения.

Метрика:

$recall@k$ - полнота, посчитанная среди k объектов с наибольшими вероятностями положительного класса.

$$recall@k = \frac{\text{число верно предсказанных моделью объектов положительного класса среди top-k}}{\text{общее число объектов положительного класса}}$$

На практике производить коммуникацию возможно только с некоторой выборкой наиболее подходящих кандидатов. Поэтому решение оценивается с помощью полноты на топ-15% тестовых данных, т.е. сначала результаты сортируются по убыванию вероятности, предсказанной моделью, а затем оценивается доля успешных регистраций, попавших в этот топ.
Подробнее: <https://habr.com/ru/companies/otus/articles/732842/>

Количество баллов рассчитывается после завершения раунда по формуле:

$Points = 400 * percentileofscore(recall@k's, recall@k)$, где $percentileofscore$ – функция, вычисляющая percentile rank, где score отсчитывается от sample submission (это решение оценивается в 0 баллов, а за любое решение с лучшим скором ставится положительный балл), $recall@k's$ – значения метрик recall @ k всех участников, $recall@k$ – значение метрики recall @ k данного участника.

Файлы

sample_submission.csv

2.48 Мб



train.zip

312.95 Мб



test.zip

77.14 Мб



[Е] Анализ клиентских обращений

К решению задач

Тренажер

Анализ данных службы поддержки позволяет оценивать качество работы сотрудников, улучшать процессы взаимодействия с пользователем и находить проблемные области. Вам предстоит выступить в качестве аналитика данных и решить задания на основе реальных данных пользовательских обращений. Вы можете использовать SQL, Pandas и другие инструменты для расчета показателей, которые помогут улучшить качество обслуживания клиентов и эффективность работы системы поддержки.

В качестве решения загрузите текстовый файл, содержащий номера вопросов и ответы на них (в одной строке - один вопрос, разделитель - запятая). Если вы решили только часть заданий, то укажите в файле номера и ответы только для этих вопросов. Пример файла с форматом отправки решение - sample_submission.txt
Максимальный балл за задачу - 100.

Задание 1: Тикеты, ожидающие обработки (10 баллов)

Необходимо вывести количество тикетов, которые на данный момент ожидают отработки агентом. Для этого используйте поле status:

- 1 — тикет отработан,
- любое другое значение — тикет требует отработки.

Если в один и тот же момент времени записано несколько логов с разными статусами для одного тикета, строки со статусом 1 не учитываются.

Задание 2: Удалённые сообщения (5 баллов)

Определите, кто удаляет сообщения чаще и в каком количестве. Рассчитайте, сколько сообщений было удалено сотрудниками, а сколько — пользователями. Выберите тех, кто удаляет сообщения чаще. В ответе укажите одно число — количество удаленных сообщений выбранной группой.

Задание 3: Повторные вопросы после закрытия по причине «троллинг» (5 баллов)

Определите количество тикетов, в которых после события event_type = 'troll_closed' пользователь задал новый вопрос (reply).

Задание 4: Анализ тегов тикетов (10 баллов)

Посчитайте количество тикетов в разрезе тегов, где тег определяется как event_subtype LIKE 'tag_%'. Учитывайте только последний тег в каждом тикете (1 тикет — 1 тег). В ответе укажите самый популярный тег.

Задание 5: Тег, который чаще всего ставят агенты (5 баллов)

Выведите тег (event_subtype), который чаще всего ставят агенты в тикетах. Рассматривайте только события с типом event_type = 'tag_set_manually' (значения в других столбцах могут быть любыми).

Задание 6: Изменение категории тикета со статусом 0 (5 баллов)

Выведите номер тикета (question_id), в котором есть запись event_type = 'set_category', если на момент записи статус тикета (status) был равен 0.

Задание 7: Расчет UWT (15)

Необходимо рассчитать показатель User Waiting Time (UWT) - среднего времени ожидания пользователем ответа сотрудника. Показатель рассчитывается на основании данных из таблицы support_questions, где фиксируются цепочки взаимодействий "вопрос пользователя" -> "ответ сотрудника". В ответе укажите среднее время в секундах с точностью до сотых.
UWT = среднее время ожидания пользователя по всем цепочкам "вопрос пользователя" -> "ответ сотрудника" за период.

Примечания:

- В качестве ответа агента необходимо учитывать строки, где event_type = 'agent_reply' (с любыми значениями в других столбцах).
- В качестве вопроса пользователя необходимо учитывать строки, где event_type = 'reply' (с любыми значениями в других столбцах).
- Пользователь может написать 2 и более вопроса подряд, в этом случае учитывается вопрос, который задан раньше.
- Сотрудник может дать 2 и более ответа подряд, в этом случае учитывается ответ, который дан раньше.
- Удаленные вопросы и ответы исключаются из расчета.

Задание 8: Расчёт SL (15 баллов)

Необходимо рассчитать показатель Service Level (SL) - процент ответов, данных в течение целевого времени (15 минут). Показатель рассчитывается на основании данных из таблицы support_questions, где фиксируются цепочки взаимодействий "вопрос пользователя" -> "ответ сотрудника". В ответе укажите значение с точностью до сотых.
SL = (количество цепочек с UWT ≤ 15 минут / общее количество цепочек) * 100%

Примечания:

- В качестве ответа агента необходимо учитывать строки, где event_type = 'agent_reply' (с любыми значениями в других столбцах).
- В качестве вопроса пользователя необходимо учитывать строки, где event_type = 'reply' (с любыми значениями в других столбцах).
- Пользователь может написать 2 и более вопроса подряд, в этом случае учитывается вопрос, который задан раньше.
- Сотрудник может дать 2 и более ответа подряд, в этом случае учитывается ответ, который дан раньше.
- Удаленные вопросы и ответы исключаются из расчета.

Задание 9: Определение скорости ответа сотрудников (10 баллов)

Определите, сотрудники с каким значением поля user_type дают самые быстрые ответы на вопросы пользователей. Для этого нужно рассчитать среднее (mean) время ответа для каждой группы сотрудников и определить группу с наименьшим средним временем ответа.
В качестве ответа агента необходимо учитывать строки, где event_type = 'agent_reply' (с любыми значениями в других столбцах). В качестве вопроса пользователя необходимо учитывать строки, где event_type = 'reply' (с любыми значениями в других столбцах).

Задание 10: Время до закрытия тикета (10 баллов)

Посчитайте среднее время от последнего действия в тикете до его закрытия по таймауту. Используйте только действия, которые произошли до события с типом event_type = 'closed_by_time'. Если в тикете было несколько таких событий, используйте последнее из них. В ответе дайте среднее (mean) количество дней с точностью до сотых.

Примечание: исключите из расчета действия, которые произошли после закрытия по таймауту.

Задание 11: Время между назначением и сбросом агента (10 баллов)

Посчитайте среднее время от назначения сотрудника до сброса (от event_type = 'set_agent' до event_type = 'drop_agent'). В ответе укажите среднее (mean) время в секундах с точностью до сотых.

Примечания:

- Учитывайте только ближайшие друг к другу события. Если было несколько событий set_agent и/или drop_agent подряд, берите последний set_agent и первый drop_agent.
- Исключите из расчета сбросы, инициированные пользователями.

Файлы

SQL_data.xlsx


8.36 Мб



sample_submission.txt

111 б





[D] Хи-Хи-Хи

Всего тестов: 50

К решению задач

Тренажер

Ограничения

по времени 1 сек по памяти 256 Мб

Аня любитель похихикать. Она даже придумала собственную оценку совместимости чувства юмора «хи-хи-хи», которая похожа на критерий хи-квадрат. Аня решила проверить, насколько её чувство юмора совместимо с Ваней.

Для этого она взяла сборник анекдотов и разбила их на несколько непересекающихся множеств. Также Аня предложила Ване разбить анекдоты на несколько непересекающихся множеств. Число множеств не обязательно должно быть одинаковым.

После этого оценка совместимости чувства юмора вычисляется по формуле: $\sum_{A,B} \frac{|o(A,B)-e(A,B)|}{e(A,B)}$ где $o(A,B)$ — реальное наблюдаемое число анекдотов, которые Аня отнесла к множеству A , а Ваня — к B , $e(A,B)$ — ожидаемое число анекдотов, если предположить, что Аня и Ваня распределяют анекдоты по группам независимо друг от друга. При этом если $e(A,B)$ равно нулю, то соответствующее слагаемое не учитывается.

Замечание

		1	2	3
В примере реальное число анекдотов выглядит как	1	1	2	0
	2	0	0	2
	1	2	3	
анекдотов	1	0.6	1.2	1.2
	2	0.4	0.8	0.8

Аня отнесла к первому множеству три анекдота, а Ваня — один. Следовательно для Ани вероятность встретить анекдот из первого множества равна $3/5$, а для Вани — $1/5$. Совместная вероятность с учётом независимости равна $3/25$, а математическое ожидание — $15/25$. Максимальный балл за задачу - 100.

Формат входных данных

Первая строка содержит два натуральных числа M и K ($1 \leq M, K \leq 10^5$) — число множеств, на которые Аня и Ваня разбили анекдоты, соответственно. При этом некоторые множества могут быть пустыми. Вторая строка содержит натуральных число N ($1 \leq N \leq 10^5$) — число анекдотов в сборнике. Следующие N строк содержат по два натуральных числа a_i и b_i ($1 \leq a_i \leq M$, $1 \leq b_i \leq K$) — номера множеств, к котором Аня и Ваня отнесли i -й анекдот.

Формат выходных данных

Выведите одно вещественное число с плавающей точкой — оценку совместимости чувства юмора «хи-хи-хи» между Аней и Ваней. Допустимая абсолютная и относительная погрешность 10^{-6} .

Пример 1

Входные данные	Выходные данные
2 3	5.833333333
5	
2 3	
1 2	
1 1	
1 2	
2 3	





[C] Поход

Всего тестов: 51

К решению задач

Тренажер

Ограничения

по времени 1 сек по памяти 256 Мб

Однажды Алексей и Майкл пошли в поход. Алексей сказал, что ему больше нравятся пешие и лыжные походы, а Майкл ответил, что ему больше нравится альпинизм. Также в ходе беседы выяснилось, что они оба любят решать олимпиадные задачи, но Алексей больше любит теорию чисел, а Майкл — функциональные уравнения.

Тогда Майкл придумал задачу на теорию чисел для Алексея. Алексей быстро решил эту задачу и в ответ придумал для Майкла задачу с функциональным уравнением. Майкл тоже справился со своей задачей, а теперь попробуйте решить её и вы.

$$f(a, b) = \begin{cases} 1 & : a = 0 \wedge b = 0 \\ 0 & : a = 0 \wedge b \neq 0 \\ 0 & : a \neq 0 \wedge b = 0 \\ f(a - 1, b) + f(a - 1 - bf(a - 1, b), b - 1) & : a \neq 0 \wedge b \neq 0 \end{cases}$$

Реализуйте программу, которая вычисляет функцию $f(a, b)$.
Максимальный балл за задачу - 100.

Формат входных данных

Даны два натуральных числа a и b ($1 \leq a, b \leq 10^{18}$).

Формат выходных данных

Выведете одно целое число — результат вычисления $f(a, b)$


Пример 1

Входные данные


3 2

Выходные данные

1



Основной этап



Завершить тест

Вопрос 1

В местной кондитерской шоколадные капкейки украшаются кондитерской посыпкой в виде разноцветных гранул. Сегодня кондитер приготовил n капкейков, при этом золотых и серебряных гранул в общей сложности осталось на m пирожных, а белых и красных хватило бы на k пирожных каждого цвета.

Сколькими способами можно украсить капкейки, если для украшения одного пирожного используется один вид гранул?

$n = 30$
 $m = 20$
 $k = 5$


Ваш ответ:

Ответом на данный вопрос является целое число или десятичная дробь. Разделителем может служить как точка, так и запятая.

Ответить



1



Завершить тест

Вопрос 1

Гарри и Рон прошли в основной тур олимпиады по искусственному интеллекту. Поскольку ни Гарри, ни Рон не готовились и ничего не знали, то они просто угадывали ответы на вопросы. Всего в отборочном туре было N вопросов. Гарри удалось угадать ответы на X вопросов, а Рону только на Y вопросов.

Найдите среднее количество вопросов в которых у Гарри и Рона получился одинаковый результат (то есть оба угадали или не угадали ответ)

$N = 30$
 $X = 18$
 $Y = 13$

Ваш ответ:

Ответом на данный вопрос является целое число или десятичная дробь. Разделителем может служить как точка, так и запятая.

Ответить



[C] Перезалив

Всего тестов: 30

К решению задач

Тренажер

Ограничения

по времени  2 сек по памяти  256 Мб

Однажды Артёму заблокировали канал на одном из видеохостингов. «Ну заблокировали и заблокировали», — подумал он и решил перезалить свои видеоролики на другие видеохостинги. Артём решил подойти к этому процессу с исследовательской точки зрения, чтобы выяснить, какой видеохостинг лучше.

Для начала Артём решил, что каждый видеоролик он загрузит ровно на один видеохостинг, чтобы у его зрителей была мотивация подписываться на все видеохостинги. Ведь, если на какой-то видеохостинг подпишется сильно больше или меньше зрителей, то это может исказить статистику просмотров.

Далее Артём решил, что минимальное и максимальное число загруженных им видеороликов на каждый видеохостинг должны отличаться как можно меньше. Ведь, если на какой-то видеохостинг будет загружено сильно больше или меньше видеороликов, то это также может исказить статистику просмотров.

Артём уже собрался загружать видеоролики на видеохостинги, но заметил, что каждый видеоролик можно отнести ровно к одной теме. Разные темы могут быть интересны разным зрителям. Поэтому Артём решил, что для ещё большей равномерности нужно загрузить видеоролики так, чтобы для каждой тематики минимальное и максимальное число загруженных видеороликов этой темы на каждом видеохостинге также отличалось как можно меньше.

Артём понял, что он слишком переусложнил себе задачу и без вашей помощи ему теперь не справиться.

Максимум баллов за задачу - 100.

Формат входных данных


Первая строка содержит три натуральных числа N, M, K ($1 \leq N \leq 10^5$, $1 \leq M, K \leq N$) — число видеороликов, тем и видеохостингов. Все они пронумерованы с единицы. Вторая строка содержит N натуральных чисел t_i ($1 \leq t_i \leq M$) — тема i -го видеоролика.

Формат выходных данных

Выведите K строк. Каждая строка x должна начинаться с целого числа S — числа видеороликов, загруженных на видеохостинг с номером x . Далее идут S целых чисел — номера соответствующих видеороликов.

Пример 1

Входные данные 	Выходные данные 
10 4 3	4 1 4 7 10
1 2 2 3 3 3 4 4 4 4	3 2 5 8
	3 3 6 9



[Е] Ценная коммуникация

[К решению задач](#)[Тренажер](#)

Банк запускает активационные кампании по кредитным картам с использованием различных каналов коммуникации. Персональные звонки клиентам – довольно затратный способ коммуникации, при этом не все клиенты позитивно реагируют на такой формат общения: кому-то будет достаточно СМС или пуш-уведомления. Ваша задача — помочь банку оптимизировать расходы на коммуникации, научившись предсказывать разницу в эффективности голосовых звонков на основе клиентских данных. В качестве решения необходимо предоставить предсказанный моделью uplift для каждого клиента из тестовой выборки.

Данные:

Используя историю взаимодействий, сессии мобильного приложения, заявки на продукты и другие признаки, вам предстоит создать модель, которая сможет повысить эффективность кампаний за счет персонализированного выбора наиболее подходящего способа общения с каждым клиентом. Признаки, которые содержатся в выборках:

- `successful_utilization` – переменная, которая показывает, воспользовался ли клиент кредитным продуктом
- `retro_date` – дата создания задачи на клиента
- `treatment` – колонка, которая показывает, имела ли место голосовая коммуникация с клиентом. 1 – с клиентом общались по голосовому каналу, 0 – с клиентом в этот момент могли общаться по голосовому каналу, но не стали
- `mb` – группа признаков, которая характеризует сессии в мобильном приложении клиента
- `application` – группа признаков, которая характеризует различные заявки клиентов на наши продукты в прошлом
- `bki` - группа признаков, которая характеризует походы клиентов в Бюро Кредитных Историй
- `partner` - группа признаков, которая характеризует различные подписки клиентов на партнерские сервисы
- `graph` - группа признаков, которая характеризует данные о контактных книжках наших клиентов
- `feature` – группа признаков, которая скрыта от описания

Метрика:

Качество решения определяется с помощью метрики Area under uplift curve (AUUQ).

Количество баллов за задание определяется по формуле:

$Points = 300 * percentileofscore(upliftaucscores, upliftaucscore)$, где $percentileofscore$ – функция, вычисляющая $percentile\ rank$ $uplift\ auc\ scores$ – значения метрик $uplift\ auc\ score$ всех участников, $uplift\ auc\ score$ – значение метрики $uplift\ auc\ score$ данного участника.

При расчете баллов используются значения метрики участников, чьи решения показали результат лучше, чем приложенный пример ответа на задачу. Решения с метрикой ниже или равной значению, полученному с помощью примера, оцениваются в 0 баллов.

Подробнее про метрику - https://habr.com/ru/companies/ru_mts/articles/538934/

Файлы

train.csv

273.60 Мб

**test.csv**

68.05 Мб

**sample_submission.csv**

1.82 Мб



?

>>





[D] Интервью

Всего тестов: 51

К решению задач

Тренажер

Ограничения

по времени 2 сек по памяти 256 Мб

Тот самый Артём из одной из предыдущих задач рассказал Юре про необычный способ разбиения видеороликов и тем по видеохостингам. Юра не смог толком понять общее правило разбиения и решил задать Артёму несколько вопросов с конкретными примерами разбиений видеозаписей. Для каждого примера Артём должен ответить, является ли он корректным или нет. Так Юра надеется понять общее правило из частных примеров.

Утомившись от однообразия вопросов, Артём решил автоматизировать свои ответы.

Максимум баллов за задачу - 100.

Формат входных данных

Первая строка содержит одно натуральное число Q ($1 \leq Q \leq 10$) — число вопросов, которые задаст Юра. Далее следуют Q вопросов. Каждый вопрос начинается со строки, которая содержит три натуральных числа N, M, K ($1 \leq N \leq 10^5, 1 \leq M, K \leq N$) — число видеороликов, тем и видеохостингов. Все они пронумерованы с единицы. Вторая строка вопроса содержит N натуральных чисел t_i ($1 \leq t_i \leq M$) — тема i -го видеоролика. Далее следует K строк, которые описывают разбиение. Каждая строка начинается с целого неотрицательного числа S — числа видеороликов, загруженных на соответствующий видеохостинг. Далее в той же строке идут S не превышающих N натуральных чисел — номера соответствующих видеороликов. Гарантируется, что сумма S по всем вопросам и видеохостингам и сумма K по всем вопросам не превышают 10^5 .

Формат выходных данных

Выведите Q строк, каждая из которых должна содержать «YES», если соответствующие разбиение корректно, и «NO» иначе.

Пример 1

Входные данные

```
2
10 4 3
1 2 2 3 3 3 4 4 4 4
4 1 2 4 8
3 7 3 5
3 9 6 10
10 4 3
1 2 2 3 3 3 4 4 4 4
4 1 2 3 4
3 5 6 7
3 8 9 10
```

Выходные данные

```
YES
NO
```



Заключительный этап

[В] Путь к Дзену

[К решению задач](#)[Тренажер](#)

В мире современных социальных сетей важно не просто наполнять ленты контентом, но и связывать его с интересами пользователей, находя взаимосвязи между постами. Грамотно настроенный механизм сопоставления контента улучшает персональные рекомендации, что повышает вовлечённость пользователей и обогащает их опыт.

В рамках данного соревнования вам предстоит разработать модель, которая определит, насколько два поста близки по смыслу и релевантны друг другу. Это могут быть не только схожие публикации, но и те, которые частично совпадают по содержанию, затрагивают одну тему под разными углами или вовсе не связаны между собой.

Данные:

Задача состоит в том, чтобы на основании заголовка и текста постов классифицировать пары по одной из категорий, для которых степень релевантности выглядит следующим образом:

`relevant_plus` > `relevant` > `relevant_minus` > `no_relevant`

Для решения Вам предоставлены три файла:

- `items.parquet` — содержит информацию об объектах: идентификаторы постов, их заголовки, контент;
- `train.csv` — содержит разметку релевантности между парами объектов;
- `test.csv` — содержит информацию о парах, для которых необходимо предоставить предсказание вашей модели в виде метки класса.

Метрика:

Качество решения определяется с помощью метрики **weighted F1-score**.

$$WeightedF1 = \sum_{i=1}^N w_i * F1_i,$$

где $F1_i$ - F1-score, посчитанный для бинарной классификации: объект принадлежит / не принадлежит классу i ,
 w_i - доля объектов класса i в выборке.

Сама метрика F1 вычисляется по формуле:

$$F1 = (2 * precision * recall) / (precision + recall)$$

Количество баллов за задание определяется по формуле:

$$Points = 100 * percentileofscore * (WeightedF1s, WeightedF1), \text{ где}$$

$Points$ – количество баллов.
 $percentileofscore$ – функция, вычисляющая percentile rank,
 $WeightedF1s$ – значения метрики $WeightedF1$ всех участников,
 $WeightedF1$ – значения метрики $WeightedF1$ данного участника.

Подробнее:

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

Файлы

train.csv

10.68 Мб



test.csv

2.01 Мб



sample_submission.csv

922.61 Кб



ТРЕБОВАНИЯ К НЕОБХОДИМЫМ ЗНАНИЯМ И УМЕНИЯМ УЧАСТНИКОВ

Олимпиада проводится в три этапа: отборочный, основной и заключительный. Чтобы решать задачи по искусственному интеллекту, необходимы знания в области математики и информатики, поэтому отборочный и основной этапы олимпиады включают задания по алгоритмам, математике, машинному обучению. В заключительном этапе олимпиады - только задачи по машинному обучению.

Комплекты заданий олимпиады состоят из преимущественно оригинальных творческих заданий, ориентированных на углубленный уровень изучения информатики и позволяющих выявить интеллектуальный потенциал, аналитические способности и креативность мышления участников.

Требования к необходимым знаниям и умениям обучающихся соответствуют уровню сложности заданий и требованиям к предметным результатам обучения информатике на углубленном уровне, установленными Федеральными государственными образовательными стандартами основного общего и среднего общего образования Российской Федерации. Уровень сложности заданий на различных этапах олимпиады определяется целями каждого этапа и ориентирован на конкретные навыки участников. Отборочный этап, как первый порог, характеризуется заданиями, оценивающими базовые знания и умения в области информатики и математики на уровне 8-9 классов. Здесь участникам предлагаются относительно простые задачи по алгоритмам, математике и анализу данных, чтобы вовлечь максимальное количество участников. Основной этап повышает сложность, фокусируясь на более глубоком понимании алгоритмов, расширенной математике, и умениях в области машинного обучения. Задачи здесь могут требовать тщательного анализа, более продвинутых алгоритмических навыков и более высокого уровня математической подготовки. Заключительный этап, как наивысший уровень сложности, предлагает участникам задания, которые проверяют их способность к решению комплексных проблем и применению знаний в реальных сценариях. Этот этап может включать задачи, требующие творческого исследования, выявления новых решений и глубокого анализа данных. Каждый этап олимпиады тщательно сбалансирован, чтобы создать прогрессивную среду для участников и предоставить им возможность продемонстрировать свой интеллектуальный потенциал и уровень подготовки в соответствии с их образовательным уровнем.

Разработанные задания направлены на демонстрацию участниками:

- владения навыками алгоритмического мышления, навыками использования интеллектуальных алгоритмов;
- знаний основных алгоритмов обработки числовой и текстовой информации, алгоритмов поиска и сортировки;
- владения представлениями о базовых типах и структурах данных, навыками планирования структуры хранения данных для последующей их обработки;
- владения навыками и опытом разработки программ, включая тестирование и отладку программ, навыками использовании программных библиотек;
- высокого интеллектуального потенциала, аналитических способностей и креативности мышления.

Комплекты заданий содержат:

- 6 заданий отборочного этапа, 6 заданий основного этапа 2 задания заключительного этапа, а также тестовые наборы данных;

- методику оценивания выполнения заданий;
- наборы данных, эталоны решений. При подготовке тестовых наборов данных учтено требование о недопустимом использовании произведений литературы, науки и искусства, маркированных 18+ в соответствии с требованиями Федерального закона Российской Федерации от 29 декабря 2010 г. № 436-ФЗ «О защите детей от информации, причиняющей вред их здоровью и развитию»;
- требования к минимальным техническим характеристикам и предустановленному программному обеспечению персональных компьютеров, используемых при проведении заключительного этапа олимпиады.

Тексты олимпиадных заданий:

- уникальны и соответствуют нормам современного русского языка: в текстах отсутствуют фактические, орфографические, пунктуационные, речевые, грамматические, стилистические ошибки;
- направлены на популяризацию знаний о технологиях искусственного интеллекта,
- соответствуют Кодексу этики в сфере искусственного интеллекта (URL: [https://ai.ru/wp-content/uploads/2021/10/Кодекс этики в сфере ИИ финальный.pdf](https://ai.ru/wp-content/uploads/2021/10/Кодекс_этики_в_сфере_ИИ_финальный.pdf)).

Отборочный этап Олимпиады. Предназначен для привлечения интереса к искусственному интеллекту. Цель этапа: проверить, насколько готов учащийся к решению задач искусственного интеллекта. Содержит относительно простые математические, алгоритмические задания и задачи по машинному обучению, проверяющие базовые основы, необходимые для решения задач искусственного интеллекта. Для выполнения заданий требуются знания математики и информатики 8-9 класса (по образовательным программам углубленного уровня). Этап включает следующие задания:

- Алгоритмы – 2 задания.
- Математика – 2 задания.
- Машинное обучение – 2 задания. Тип задачи: анализ данных и регрессия.

Отборочный этап Олимпиады проводится дистанционно.

Ниже представлены необходимые знания для решения задач отборочного этапа (8-11 класс, углубленный уровень).

Алгоритмы:

- Язык программирования (Python, C++, Java, C#) Система программирования: редактор текста программ, транслятор, отладчик.
- Переменная: тип, имя, значение. Целые, вещественные и символьные переменные.
- Оператор присваивания. Арифметические выражения и порядок их вычисления. Операции с целыми числами: целочисленное деление, остаток от деления. Проверка делимости одного целого числа на другое.
- Операции с вещественными числами. Встроенные функции. Случайные (псевдослучайные) числа.
- Ветвления. Составные условия (запись логических выражений на изучаемом языке программирования). Нахождение минимума и максимума из двух, трёх и четырёх чисел. Решение квадратного уравнения, имеющего вещественные корни. Логические переменные.
- Цикл с условием. Цикл с переменной.
- Анализ алгоритмов. Определение возможных результатов работы алгоритма при заданном множестве входных данных; определение возможных входных данных, приводящих к данному результату.

- Обработка символьных данных Символьные (строковые) переменные. Посимвольная обработка строк. Встроенные функции для обработки строк.
- Табличные величины (массивы) Одномерные массивы. Составление и отладка программ, реализующих типовые алгоритмы обработки одномерных числовых массивов, на одном из языков программирования (Python, C++, Java, C#).
- Множества, хеш-таблицы, отображения, словари.

Математика:

- Иррациональные числа. Числовые множества. Измерения, приближения, оценки.
- Уравнения. Неравенства. Функции. Многочлены.
- Числовые последовательности и прогрессии.
- Множество и подмножество. Элементарные события. Вероятности случайных событий. Опыты с равновероятными элементарными событиями. Случайный выбор.
- Дерево. Дерево случайного эксперимента. Свойства деревьев: единственность пути, связь между числом вершин и числом рёбер. Понятие о плоских графах. Решение задач с помощью деревьев.
- Случайные события как множества элементарных событий. Противоположные события. Операции над событиями. Формула сложения вероятностей.
- Геометрическая вероятность. Случайный выбор точки из фигуры на плоскости, из отрезка, из дуги окружности.
- Случайная величина и распределение вероятностей. Примеры случайных величин. Важные распределения — число попыток в серии испытаний до первого успеха и число успехов в серии испытаний Бернулли (геометрическое и биномиальное распределения).
- Математическое ожидание случайной величины. Физический смысл математического ожидания. Примеры использования математического ожидания. Дисперсия и стандартное отклонение случайной величины. Свойства математического ожидания и дисперсии. Математическое ожидание и дисперсия изученных распределений.

Машинное обучение

- Табличные данные. Предобработка данных. Работа с пропущенными значениями. Отбор признаков. Разведочный анализ данных. SQL запросы.
- Задача регрессии. Методы решения. Модели. Функции потерь. Метрики качества.
- Знание библиотек для работы с данными: scikit learn, pandas
- Градиентный бустинг. Знаний библиотек для работы моделями бустинга: scikit learn, xgboost, catboost, lightgbm

Ориентировочное время решения задач:

- Математика: 1 час на каждую из двух задач
- Алгоритмы: 1 час на каждую из двух задач
- Машинное обучение: 2 дня на каждую из задач

Основной этап Олимпиады. Предназначен для проверки способности решать стандартные задачи в области математики, информатики и машинного обучения. Этап включает следующие задания:

- Алгоритмы – 2 задания.
- Математика – 2 задания.
- Машинное обучение – 2 задания. Тип задачи: классификация текстов на русском языке.

Основной этап Олимпиады проводится дистанционно.

Направления задач по искусственному интеллекту:

- Классификация аудио.
- Создание модели для рекомендательной системы.

Задачи эквивалентного уровня сложности, т.к. для их решения достаточно применить стандартные существующие подходы в соответствующих областях.

Для выполнения заданий требуются знания математики и информатики 8-11 класса углубленного уровня.

Алгоритмы:

- Основы алгоритмического мышления: понятие алгоритма, свойства хорошего алгоритма, примеры алгоритмического мышления в повседневной жизни.
- Оценка сложности алгоритмов: обзор различных методов оценки эффективности алгоритмов, асимптотический анализ сложности.
- Поиск и сортировка: реализация и анализ различных алгоритмов поиска элемента в массиве (линейный поиск, двоичный поиск) и сортировки массива (сортировка пузырьком, сортировка выбором, быстрая сортировка, сортировка слиянием).
- Структуры данных: обзор и реализация различных структур данных, таких как массивы, списки, стеки, очереди, хеширование и деревья.
- Графы и алгоритмы на графах: обзор графовых структур данных, таких как ориентированные и неориентированные графы, алгоритмы обхода графов (поиск в ширину и поиск в глубину), алгоритм Дейкстры и алгоритм Флойда-Уоршелла для поиска кратчайшего пути.
- Динамическое программирование: основные принципы динамического программирования, примеры применения.
- Решение задач на жадные алгоритмы: представление жадных алгоритмов, основные примеры.
- Методы оптимизации, градиентный спуск, решение систем линейных уравнений.

Математика:

- Решение систем линейных уравнений. Матрица системы линейных уравнений. Решение прикладных задач с помощью системы линейных уравнений. Исследование построенной модели с помощью матриц и определителей.
- Построение математических моделей реальной ситуации с помощью уравнений и неравенств. Применение уравнений и неравенств к решению математических задач и задач из различных областей науки и реальной жизни.
- Функциональные зависимости в реальных процессах и явлениях. Графики реальных зависимостей.
- Первая и вторая производные функции. Определение, геометрический и физический смысл производной. Уравнение касательной к графику функции.
- Производные элементарных функций. Производная суммы, произведения, частного и композиции функций.

- Множества и логика. Множество, операции над множествами и их свойства . Диаграммы Эйлера–Венна. Применение теоретико-множественного аппарата для описания реальных процессов и явлений, при решении задач из других учебных предметов.
- Применение производной к исследованию функций на монотонность и экстремумы. Нахождение наибольшего и наименьшего значений непрерывной функции на отрезке .
- Применение производной для нахождения наилучшего решения в прикладных задачах, для определения скорости и ускорения процесса, заданного формулой или графиком.
- Граф, связный граф, пути в графе: циклы и цепи. Степень (валентность) вершины. Графы на плоскости. Деревья.
- Случайные эксперименты (опыты) и случайные события. Элементарные события (исходы) . Вероятность случайного события. Близость частоты и вероятности событий. Случайные опыты с равновозможными элементарными событиями.
- Операции над событиями: пересечение, объединение, противоположные события. Диаграммы Эйлера. Формула сложения вероятностей.
- Условная вероятность. Умножение вероятностей. Дерево случайного эксперимента. Формула полной вероятности. Формула Байеса. Независимые события.
- Совместное распределение двух случайных величин. Независимые случайные величины.
- Математическое ожидание случайной величины (распределения). Примеры применения математического ожидания (страхование, лотерея). Математическое ожидание бинарной случайной величины. Математическое ожидание суммы случайных величин. Математическое ожидание геометрического и биномиального распределений.
- Ковариация двух случайных величин. Коэффициент линейной корреляции. Совместные наблюдения двух величин. Выборочный коэффициент корреляции. Различие между линейной связью и причинно-следственной связью. Линейная регрессия, метод наименьших квадратов.

Машинное обучение:

- Табличные данные. Предобработка данных. Работа с пропущенными значениями. Отбор признаков. Разведочный анализ данных.
- Знание алгоритмов создания рекомендательных систем, коллаборативная фильтрация.
- Знание библиотек для работы с данными: scikit learn, pandas
- Глубокие нейронные сети для обработки звука. Знание нейросетевых библиотек TensorFlow, PyTorch, Hugging Face.
- Задача классификации. Методы решения. Модели. Функции потерь. Метрики качества.
- Умение использовать предварительно обученные нейронные сети для задач классификации.

Ориентировочное время решения задач:

- Математика: 1 час на каждую из двух задач
- Алгоритмы: 1 час на каждую из двух задач
- Машинное обучение: 2 дня на каждую из задач

Заключительный этап Олимпиады. Содержит две задачи по машинному обучению повышенной сложности на основе реальных данных от компании-партнера VK. Направления заданий:

- Определение релевантности изображения и поискового запроса.
- Создание модели для предсказания вероятности взаимодействия с рекламным объявлением.

Финал Олимпиады проводится очно. Оборудование для решения задач предоставляется организаторами.

Отличительными особенностями заданий заключительного этапа олимпиады являются:

- *Высокий уровень сложности.* Задания предполагают работу с реальными наборами данных от компании. В отличие от учебных наборов данных, простой запуск стандартных алгоритмов искусственного интеллекта на реальном наборе данных без предварительной подготовки не даст качественного решения. Поэтому участникам придется выполнить подготовку реального набора данных для решения требуемых задач: предварительную обработку, очистку, поиск ликов и т.п. В дополнение к предварительной подготовке набора данных, для получения качественного решения задачи потребуется оптимизировать гиперпараметры модели и процесса обучения. Дополнительную сложность добавит достаточно большой объем данных, с которыми придется работать. Поэтому операции предварительной обработки данных и обучения модели будут требовать значительного времени.
- *Оригинальность.* Задачи используют оригинальные наборы данных от компании-партнера VK. Ранее эти наборы данных не были использованы в образовательных или академических целях.
- *Творческий характер.* Сложность задачи, большой объем данных и длительное время обучения модели не позволяют получить качественное решение простым перебором всех возможных стандартных подходов. Поэтому участникам придется выбирать, какие именно решения имеет смысл попробовать в имеющееся ограниченное время. Участники могут попробовать реализовать идеи по планированию процесса экспериментов, оптимизации процесса обучения моделей, расширить или уменьшить набора данных, а также использовать любые другие подходы, позволяющие за короткий срок получить качественное решение.

Требования в области искусственного интеллекта:

- Глубокие нейронные сети для обработки изображений и текста. Мультимодальные модели. Использование предварительно обученных нейронных сетей для работы с изображениями и текстами. Знание библиотек глубоких нейронных сетей: TensorFlow, PyTorch, Hugging Face.
- Табличные данные. Предобработка данных. Работа с пропущенными значениями. Отбор признаков. Разведочный анализ данных. Знание библиотек для работы с данными: scikit learn, pandas
- Задача классификации. Методы решения. Модели. Функции потерь. Метрики качества.
- Градиентный бустинг. Знаний библиотек для работы моделями бустинга: scikit learn, xgboost, catboost, lightgbm

Ориентировочное время решения задач:

- Машинное обучение: 6 часов на каждую из задач с перерывом на 1 час

Требования к оборудованию рабочих мест участников

Рекомендуемые системные требования для участников заочных и заключительного этапа:

- Процессор с тактовой частотой ядра не менее 2,1 ГГц и количеством ядер не менее 6.
- Оперативная память не менее 16 гб.
- Жесткий диск SSD на менее 128 гб.
- Видеокарта внешняя Nvidia с объемом видеопамати от 8 гб.
- ОС Windows.
- Монитор не менее FHD (1920*1080), 60Hz
- Клавиатура, мышь

Для заочных этапов допускается, что тип памяти, количество оперативной памяти, объем видеопамати, частота процессора могут отличаться в меньшую сторону от заявленных в рекомендации характеристик.

В случае отклонения от указанных выше характеристик участникам потребуется больше времени для решения заданий, отладки своего кода на компьютере. С учетом сроков отборочного и основного этапа это не влияет на результат. А для заочного этапа критично время обучения модели на компьютерах участников.

РЕСУРСЫ ДЛЯ ПОДГОТОВКИ

- Математика:
 - <https://problems.ru>
 - http://mathprofi.ru/teorija_verojatnostei.html
 - <https://foxford.ru/wiki/matematika/grafy>
- Алгоритмы:
 - <https://stepik.org/course/156/>
 - <https://leetcode.com/>
 - Томас Х. Кормен, Чарльз И. Лейзерсон, Рональд Л. Ривест, Клиффорд Штайн. Алгоритмы: построение и анализ, 3-е издание = Introduction to Algorithms, Third Edition. — М.: «Вильямс», 2013. — 1328 с. — ISBN 978-5-8459-1794-2.
- Машинное обучение:
 - <https://academy.vandex.ru/handbook/ml>
 - <https://openedu.ru/course/hse/INTRML/>
 - Гудфеллоу, Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилль ; перевод с английского А. А. Слинкина. — 2-е изд. — Москва : ДМК Пресс, 2018. — 652 с. — ISBN 978-5-97060-618-6. — Текст : электронный // Лань : электронно-библиотечная система. — URL: <https://e.lanbook.com/book/107901>
 - <https://www.kaggle.com/learn>
 - <https://scikit-learn.org/stable/tutorial/index.html>
 - <https://pytorch.org/tutorials/>

ТРЕБОВАНИЯ К ОБОРУДОВАНИЮ РАБОЧИХ МЕСТ

Рекомендуемые системные требования для участников заочных и заключительного этапа:

- Процессор с тактовой частотой ядра не менее 2,1ГГц и количеством ядер не менее 6.
- Оперативная память не менее 16 гб.
- Жесткий диск SSD на менее 128 гб.
- Видеокарта внешняя Nvidia с объемом видеопамати от 8 гб.
- ОС Windows.
- Монитор не менее FHD (1920*1080), 60Hz
- Клавиатура, мышь

Для заочных этапов допускается, что тип памяти, количество оперативной памяти, объем видеопамати, частота процессора могут отличаться в меньшую сторону от заявленных в рекомендации характеристик.

В случае отклонения от указанных выше характеристик участникам потребуется больше времени для решения заданий, отладки своего кода на компьютере. С учетом сроков отборочного и основного этапа это не влияет на результат. А для заочного этапа критично время обучения модели на компьютерах участников.