

Что такое анализ данных?

Пусть есть социальная сеть, в которой пользователи могут выкладывать публикации, связанные с животными. Под каждой публикацией пользователи могут поставить “сердечко” – кнопка, которая показывает, что пользователю понравилась запись.

Давайте проведём эксперимент и обновим дизайн интерфейса. Как понять изменилась ли вовлеченность пользователя? Для этого возьмём две группы пользователей:

- Контрольная группа – пользователи из неё будут видеть старый интерфейс
- Экспериментальная группа – пользователи из неё будут видеть новый интерфейс

Итак, анализ данных – это процесс поиска ответов на вопросы на основе данных.

Навыки исследовательского анализа данных(EDA) пригодятся, чтобы выполнить следующие действия:

- Подготавливать данные, на которых будет обучаться модель МО
- Искать скрытые зависимости в данных, чтобы точнее настроить модель

Давайте рассмотрим искусственные данные о фильмах

Жанр фильма	Страна производства	Год производства	Продолжительность, часы	Продолжительность, минуты
Триллер	Германия	2011	1	36
Комедия	США		Нет данных	35
Боевик	Россия	2007	2	11
Документальный	США — Германия	2015	Нет данных	36
Биография	Италия		1	58

Факторы, которые описывают каждый из фильмов, следующие: “Жанр фильма”, “Страна производства”, “Год производства”, “Продолжительность в часах” и “Продолжительность в минутах”.

На примерах этой таблицы обсудим проблемы, которые могут возникнуть на этапе предобработки:

- 1. Отсутствующие значения. Для некоторых фильмов не указан год производства — не все ячейки в этом столбце заполнены. Если модели понадобится использовать этот столбец для предсказания какой-то характеристики, она просто не сможет это сделать**
- 2. Неправильный тип значений. Рассмотрим колонки «Продолжительность, часы» и «Продолжительность, минуты». Представим, что данные достались нам уже в готовом виде, и люди, собиравшие эти данные, вписывали «Нет данных» в колонку «Продолжительность, часы», если продолжительность фильма была меньше часа. Если считать эту колонку в память компьютера, он будет воспринимать все значения в этой колонке как строки, а не как числа, поскольку ему придётся привести числа и текст к единому формату.**
- 3. Неоптимально выбранные факторы. Колонки «Продолжительность, часы» и «Продолжительность, минуты» содержат непоказательные данные — естественнее было бы работать с общей продолжительностью фильма, например в минутах. Нужно агрегировать информацию из этих двух колонок и создать новую колонку.**
- 4. Скрытые значения. В факторе «Страна производства» также указаны разнородные данные. Фильм может быть произведён как в одной стране, так и в нескольких. Во втором случае в столбце**

указаны названия всех стран, принимавших участие в создании фильма, через тире. Компьютер считает этот столбец как строки и по умолчанию будет считать все посимвольно отличающиеся значения из этого столбца независимыми категориями. Например, категории «Германия» и «США — Германия» будут абсолютно равнозначны, и модель не сможет узнать, что фильмы с соответствующими значениями этого фактора в некотором роде связаны между собой.

Способ хранения данных

Для хранения данных используют файлы расширения .csv (Comma Separated Values). Это означает что в каждой строке указаны колонки и их значения, разделённые запятыми.

Если файлы все названия и значения не имеют запятых, то использовать можно стандартную запятую.

```
import pandas as pd
pd.read_csv("start.csv", sep = ",")
```

start.csv

День, Месяц, Год

01, 01, 1992

02, 02, 1400

Таблица

День	Месяц	Год
01	01	1992
02	02	1400

Иначе если есть колонки или значения с названиями формата “1,2” или “Город, место” нужно использовать “;” в качестве делителя.

Просмотр содержимого таблицы

Существует несколько подходов к просмотру содержимого таблицы pandas.

- 1. Просмотр конкретной колонки. Обратиться к какой-то конкретной колонке так же, как происходит обращение к какому-то элементу списка в Python.**

`movies['Год производства']` — результатом исполнения этого кода является колонка «Год производства» таблицы, которая хранится в переменной `movies`.

- 2. Просмотр части таблицы. Для этого можно в аналогичной предыдущему случаю манере запросить не одну, а несколько колонок.**

`movies[['Год производства', 'Страна производства']]` — результатом исполнения этого кода является таблица, содержащая две колонки: «Год производства» и «Страна производства».

- 3. Просмотр конкретной строки в таблице. Для этого нужно воспользоваться конструкцией `iloc`, которая доступна у каждой таблицы.**

`movies.iloc[2]` — результатом исполнения этого кода

является 3-я строка заданной таблицы, если считать с 1.

Визуализация данных

Для визуализации данных в python обычно используют библиотеку seaborn.

В seaborn существует большое количество функций для построения различных графиков, однако для проведения исследовательского анализа данных наиболее полезными являются три функции.

1. График зависимости одной величины от другой

График зависимости одной величины от другой представляет собой отображение на плоскости множества точек, у которых в качестве координаты x выступает значение одной величины, а в качестве координаты y — значение другой величины.

Для построения соответствующего графика в seaborn используется функция scatterplot. Например, следующий код построит график зависимости значений фактора «Общая продолжительность» от значений фактора «Год производства»:


```
sns.scatterplot(x=movies['Год производства'],  
                y=movies['Общая продолжительность'])
```

В качестве x и y здесь возможно передать списки соответствующих координат любого набора точек.

Возможен второй режим использования функции, в котором ей явно сообщают, что работа происходит с таблицей pandas. Это позволяет напрямую обращаться к колонкам таблицы при построении графика:

```
sns.scatterplot(data=movies,  
                x='Год производства',  
                y='Общая продолжительность')
```

В результате исполнения функции будет построен следующий график.



2. График распределения

Ещё одним полезным графиком при анализе данных является график распределения значений. На нём показано, сколько раз встречается каждое значение в заданном наборе данных.

Из-за того, что различных значений величины может встречаться довольно много, принято рассматривать не каждое значение в отдельности, а диапазоны значений, и подсчитывать, сколько раз значения из каждого диапазона встречаются .


Чтобы построить график распределения с помощью seaborn, нужно воспользоваться функцией histplot. Она принимает в качестве аргумента набор значений (в частности, колонку таблицы), распределение которых нужно построить, а также необязательный ключевой аргумент bins — количество диапазонов, на которые нужно разбить множество возможных значений при построении графика.

Построение с помощью функции распределения значений в колонке «Год производства» выглядит следующим образом:

```
sns.histplot(movies['Год производства'],  
             bins=len(movies['Год производства'].unique()))
```

В данном примере в качестве числа интервалов указано число возможных значений года производства фильма. Чтобы установить список возможных уникальных значений какой-то колонки, можно воспользоваться функцией unique.

В результате исполнения функции будет построен следующий график.



3. Графики зависимости каждого фактора от каждого другого фактора


В seaborn существует возможность построить графики зависимости каждой колонки какой-то таблицы от каждой другой колонки этой таблицы. Для этого нужно воспользоваться функцией `pairplot`, передав в неё исходную таблицу:

```
sns.pairplot(movies[['Год производства', 'Общая продолжительность']])
```


В примере построение графиков идёт по подтаблице таблицы `movies`, которая состоит из двух колонок: «Год производства» и «Общая продолжительность».

В результате исполнения функции будет построена следующая таблица из графиков.

Год производства



Общая продолжительность



Год производства

Общая продолжительность

